基于 TCGA-BRCA 多组学融合的乳腺癌分子亚型分类研究

YuYe10　Cancer-Classification Project

2026 年 4 月

摘要

我们围绕课程任务“单癌种（BRCA）内部的分子亚型分类”完成了可复现的多组学实验。基于 TCGA-BRCA 的 RNA-seq、DNA 甲基化与 PAM50 标签，我们在统一 repeated stratified CV（5 folds × 3 repeats）口径下比较了 RNA-only、Concat、MOFA 和 Stacking 四条主线。为保证公平性，特征筛选、标准化、MOFA 拟合与 Stacking 元特征构造均严格限定在训练折内，测试折仅用于独立推断。

在当前数据对齐结果下，HER2 类样本数不足（< 2）被自动剔除。主结果显示：Concat 的 Accuracy 最优（0.9012，95% CI [0.8609, 0.9415]），RNA-only（0.8655）与 Stacking（0.8488）次之，MOFA（0.7857）波动较大。置换检验显示组间差异尚未达到显著水平，说明在小样本条件下应优先解读“稳定趋势 + 置信区间”而非单一高分。整体上，我们完成了课程要求的数据整合、算法比较、分类评估与研究报告闭环，并明确了后续提升路径。

关键词： 多组学融合；乳腺癌；TCGA-BRCA；分子亚型分类；MOFA；Stacking；严格交叉验证

目录

1 背景与研究动机 **4**

1.1 乳腺癌分子异质性与分型的临床重要性 4

1.2 单一组学数据的表型解释局限性 4

1.3 多组学融合方法的发展轨迹与应用潜力 5

1.4 本研究的科学设计与核心问题 5

2 相关工作 **6**

2.1 TCGA 驱动的癌症分型研究 6

2.2 多组学融合的经典路线 7
2.3 MOFA 与潜在因子学习 7
2.4 图神经网络与更广义的 AI 方法 7
2.5 本文的位置 8

3 数据来源与预处理 8
3.1 TCGA 与 UCSC Xena 数据资源 8
3.2 RNA-seq 数据特点 8
3.3 DNA 甲基化数据特点 8
3.4 临床标签与样本对齐 9
3.5 训练-测试划分与防泄露原则 9
3.6 标签映射 9

4 方法 10
4.1 总体流程 10
4.2 四种方法定义 10
4.2.1 RNA-only 10
4.2.2 Concat（早期融合） 10
4.2.3 MOFA（潜表示融合） 11
4.2.4 Stacking（晚期融合） 11
4.3 偏倚控制与可复现性 11
4.4 本研究的创新点定位（课程任务视角） 12

5 实验设置 12
5.1 实验目标 12
5.2 课程任务对照 12
5.3 数据与任务 13
5.4 评估协议 13
5.5 指标与统计 13
5.6 为什么统一使用线性 SVM 14
5.7 实现入口 14
5.8 结果解释原则 14

6 结果统计框架 15
6.1 评估原则 15
6.2 统计量定义 15

6.3 比较原则 15
6.4 显著性检验说明 15

7 结果与可视化分析 16
7.1 主实验结果汇总（严格 CV） 16
7.2 性能差异解释 16
7.3 可视化证据 17
7.4 类别级误差分析 19
7.5 小结 20
7.6 可解释性分析（SHAP） 20

8 讨论 21
8.1 为什么做这项研究 21
8.2 方法差异的解释 21
8.3 为什么严格 CV 是主结论口径 21
8.4 MOFA 的价值与边界 21
8.5 当前局限 22
8.6 后续工作 22
8.7 本研究的 novelty 边界声明 22
8.8 详细继续改进方案 23

9 结论 23

10 参考文献 24

1 背景与研究动机

1.1 乳腺癌分子异质性与分型的临床重要性

乳腺癌作为全球高发恶性肿瘤，在诊断、治疗和预后评估中面临显著的生物学异质性挑战。虽然形态学分类（如组织学分级、TNM 分期）提供了基础的风险评估框架，但临床实践已充分证明，相同的病理分级往往预示着截然不同的临床结局。这一现象的根源在于肿瘤发生、演进与药物应答过程中存在深层的分子机制差异。

分子亚型的引入彻底改变了乳腺癌的临床管理范式。基于基因表达谱，Parker 等人（2009）首次定义了 PAM50 分子亚型系统，将乳腺癌分为 Luminal A、Luminal B、HER2-enriched 和 Basal-like 四个类别，这些亚型在激素受体表达状态、细胞增殖活跃程度、药物敏感性和长期生存期上存在显著区别。

- **Luminal A**：激素受体阳性、HER2 阴性、增殖指数低，具有最优的预后
- **Luminal B**：激素受体阳性、增殖指数高或 HER2 阳性，中等预后
- **HER2-enriched**：HER2 过表达驱动，靶向治疗敏感性高
- **Basal-like**：激素受体阴性、增殖指数最高、预后最差

从治疗策略的角度看，分子亚型分类直接指导患者的个体化治疗方案：Luminal 亚型受益于内分泌治疗与 CDK4/6 抑制剂；HER2-enriched 亚型需要 HER2 靶向治疗（如曲妥珠单抗）；Basal-like 亚型通常对化疗敏感但内分泌治疗无效。因此，准确的分子亚型分类不仅具有科学价值，更直接关乎患者的治疗效果和生存预期。

1.2 单一组学数据的表型解释局限性

虽然基因表达数据在乳腺癌亚型分类中已建立起坚实的地位，但单一的转录组视角往往无法完整解释表型多样性。从生物学机制的深度来看，肿瘤的表型是多个调控层次的综合结果：

1. **基因型层面**：DNA 序列变异、拷贝数变异和结构变异
2. **表观遗传层面**：DNA 甲基化、组蛋白修饰等形成的异常调控
3. **转录层面**：mRNA 和 lncRNA 的表达改变
4. **蛋白层面**：翻译后修饰和蛋白定位
5. **代谢层面**：关键代谢通路的重编程

6. **微环境层面**：免疫细胞、基质细胞的相互作用

仅使用 RNA-seq 数据进行分类具有以下局限：

(a) 调控机制掩蔽：某些基因可能由于启动子甲基化而被沉默，其 RNA 表达量反映的是最终结果，而非触发因素。两个表型相似的样本在 RNA 水平上表现接近，但甲基化驱动的调控状态可能差异巨大，这会影响长期的演进轨迹和对某些治疗的响应。

(b) 噪声与可变性：RNA 表达易受技术因素（如测序深度、批处理效应）和生物学因素（如细胞周期、微环境波动）影响。单一模态难以区分真正的表型差异与暂时的表达波动。

(c) 亚型边界的模糊性：传统基于表达阈值的分类往往存在连续性，而非离散的类别分界。相邻亚型样本在表达空间中相互接近，增加了分类错误率。

通过整合多组学信息，特别是将表达数据与甲基化调控信息联合，可以从多维度同时刻画肿瘤表型，实现更稳健、更准确的分类。

1.3 多组学融合方法的发展轨迹与应用潜力

多组学融合的发展经历了三个主要阶段：

第一阶段：特征拼接（Feature Concatenation）。最直观的融合方式是将不同模态的特征向量直接拼接，形成超高维特征空间。这种方法实现简单，但面临维度诅咒问题：在 $n \ll p$ 的环境下（样本数远小于特征数），模型极易过拟合。虽然如此，适当的特征选择后，拼接方法在乳腺癌分类中仍表现出竞争力。

第二阶段：表示学习（Representation Learning）。深度学习时代涌现了 Autoencoder、VAE、MOFA 等方法，它们试图先学习每个模态的低维表示，再进行融合。MOFA 是该阶段的代表性方法，它通过解析模式（Probabilistic Factor Model）建立可解释的潜因子结构，既能降低维度，又能对因子进行生物学解释。

第三阶段：结构化学习（Structure-aware Learning）。近期的方法倾向于显式引入生物网络结构，如蛋白质相互作用网络（PPI）、基因调控网络（GRN）等，通过图神经网络或路径分析获取更具有生物学意义的特征。

在本研究中，我们选择在前两阶段的框架内进行深入探索，通过对比拼接与 MOFA 两种策略的性能，评估表示学习在当前问题中的实际增益。这一选择既实用，又有助于揭示融合策略与任务特异性的关系。

1.4 本研究的科学设计与核心问题

本研究的设计围绕三个核心科学问题展开：

核心问题 1：多组学融合是否能显著改进乳腺癌亚型分类的准确性与稳健性？我们的假设是通过整合表达与甲基化信息，模型能够从更多维度捕获亚型特异性的生物学特征，从而超越单一模态的性能基准。

核心问题 2：不同融合策略（早期拼接、潜表示融合、晚期集成）在这一任务中的相对效能如何？我们预期潜表示融合（MOFA）可通过低维因子压缩噪声，晚期融合（Stacking）可通过分支级决策集成提升泛化能力，但两者都对样本规模与参数配置更敏感。

核心问题 3：特征筛选与预处理顺序在高维小样本分类中的关键程度？我们预期特征筛选与避免数据泄露的预处理顺序对分类性能的影响至关重要，其重要性甚至可能超过融合策略本身。

为了系统地回答这些问题，我们设计了以下实验体系：

- **主线对比实验**：在相同的数据分割与评估方案下，对 RNA-only、Concat、MOFA、Stacking 四种方案进行对标
- **稳健性验证**：采用重复分层交叉验证与统计检验评估结果可靠性
- **误差解释**：结合指标分布与置信区间分析性能差异来源

本文后续章节将围绕数据来源、特征处理、模型构建、实验设置和结果分析展开，力求在提供可复现框架的同时，通过严谨的方法设计回答上述科学问题。

2 相关工作

2.1 TCGA 驱动的癌症分型研究

TCGA 平台推动了癌症分子分型研究从“单指标判断”走向“多组学联合分析”。在 TCGA 出现之前，很多肿瘤分型工作依赖病理图像、少量基因集合或有限临床特征，难以充分刻画肿瘤内部的分子异质性。TCGA 的价值在于，它不仅提供了跨癌种、跨队列的统一数据资源，也提供了标准化分析入口，使得不同研究者能够在较为一致的数据框架下比较算法效果。

围绕 TCGA 的分子分类任务，研究者最初主要采用传统统计学与机器学习方法，例如差异分析、单因素筛选、LASSO、SVM、随机森林等。这一阶段的核心目标是把高维组学数据压缩到可解释、可训练的子集，再在此基础上完成分类或生存分析。由于数据样本量通常不大、特征维度极高，这类方法长期以来仍然是最稳定的基线选择。

2.2 多组学融合的经典路线

多组学融合研究一般可以划分为三条主线。第一条主线是早期融合（early fusion），即把不同组学经过对齐和预处理后直接拼接到同一输入空间中。Concat 属于这类方法的最简实现，其优点是简单直接、易于比较，缺点是无法显式建模组学之间的交互。

第二条主线是中期融合或表示学习，即先对每个组学提取低维表示，再在表示空间进行融合。MOFA、AE、VAE 等方法都属于这一类。与直接拼接相比，这类方法能够显式压缩噪声、增强共享结构，并为后续解释提供潜在因子或嵌入向量。

第三条主线是后期融合或决策级融合，即每种组学各自训练一个模型，再在输出层进行投票、加权或堆叠。后期融合更容易处理模态异构性，但往往难以利用跨模态共享结构，因此在强监督任务中不一定优于中期融合。

2.3 MOFA 与潜在因子学习

MOFA（Multi-Omics Factor Analysis）是多组学研究中最具代表性的潜变量模型之一。其核心思想是通过矩阵分解提取跨组学共享的低维潜在因子，同时保留每个组学的特有变化。与深度学习模型相比，MOFA 的优势不在于大规模非线性表达能力，而在于可解释性与稳定性。它非常适合“样本不多、组学很多、希望解释因子意义”的生物医学任务。

在乳腺癌、卵巢癌、神经胶质瘤等 TCGA 数据上，MOFA 常被用来做亚型分离、潜在结构发现和特征解释。很多研究会把 MOFA 先作为无监督表征学习步骤，再把输出的因子喂给分类器。本文采用的策略与这一思路一致：先学习低维因子，再用 SVM 完成分类，从而兼顾表示学习与分类性能。

2.4 图神经网络与更广义的 AI 方法

近年来，多组学分类研究也逐渐引入图神经网络、对比学习、自监督预训练与生成式模型等方法。图神经网络的优势在于能显式建模“基因-基因”“样本-样本”或“通路-通路”之间的关系，因此在某些任务中能够捕获单纯矩阵模型难以表达的结构信息。对比学习与自监督方法则更强调在标注有限时学习稳健表征，这对于临床数据稀缺场景很有吸引力。

不过，这些新方法大多带来更高的实现复杂度，也更依赖图构建方式、负样本定义、预训练策略和大规模数据支持。相较之下，本文的目标不是追求模型谱系的最前沿，而是以一个可复现、可解释、便于课程报告展示的框架，系统比较传统多组学路线的实际效果。

2.5 本文的位置

从研究谱系上看，本文属于“传统机器学习 + 潜在表示学习”的组合式多组学研究。它的价值不在于提出全新模型，而在于把当前仓库中的工程实现与多组学经典方法联系起来，形成一个逻辑完整、方法可解释、实验可复现的研究报告。这样的定位适合教学、汇报与课程论文写作，也便于后续继续扩展到更复杂的方法。

3 数据来源与预处理

3.1 TCGA 与 UCSC Xena 数据资源

TCGA（The Cancer Genome Atlas）是癌症研究领域最重要的公共多组学数据库之一，覆盖了大量癌种的基因组、转录组、表观组、蛋白组以及临床信息。其数据规模大、注释较完整、样本来源统一，因此非常适合用于多组学方法研究。UCSC Xena 则提供了 TCGA 及其他公共项目的统一下载与可视化入口，使研究者能够较为方便地获取不同组学的标准化矩阵和临床标签。

本研究采用的 TCGA-BRCA 数据包含三类核心信息：RNA-seq 表达矩阵、DNA 甲基化矩阵以及临床亚型标签。当前仓库中已经整理好的数据文件分别位于 `datasets/TCGA-BRCA.star` `datasets/TCGA-BRCA.methylation450.csv` 与 `datasets/brca_pam50.csv`。其中，RNA 和甲基化矩阵均以“特征 × 样本”的形式组织，临床文件用于提供监督学习标签。

3.2 RNA-seq 数据特点

RNA-seq 数据在本研究中承担最基础的功能表达信息角色。转录组矩阵记录了每个基因在不同样本中的表达水平，其维度通常较高，且表达分布具有明显偏态：少量高表达基因占据较大信号，而大量低表达基因对分类的贡献有限。因此，RNA 预处理通常需要进行对数变换、低表达过滤与高方差特征筛选。

当前实现采用 `log2(TPM + 1)` 形式进行数值变换，以压缩极端值并缓解表达量分布不均问题。随后使用均值过滤与方差排序保留高区分度特征。这个步骤在实验中起到两个作用：一是降低噪声，二是避免模型被大量无关基因拖累。对于高维小样本场景而言，这类特征筛选往往比复杂的深度模型更稳定。

3.3 DNA 甲基化数据特点

甲基化数据反映的是 CpG 位点上的表观遗传状态，其维度更高，典型平台（如 Illumina 450K）可能包含数十万条 probe。与 RNA 不同，甲基化数据的解释通常更偏

向调控层面：某些启动子区域的甲基化升高可能导致相关基因沉默，而不同亚型在甲基化谱上的差异往往反映其调控机制的变化。

由于甲基化数据极高维且稀疏，若直接进入分类器，很容易出现严重过拟合。因此本研究同样采用高方差筛选策略，只保留最具区分度的 probe。当前代码中，甲基化预处理会先删除缺失值，再按方差排序保留 Top-K 特征。该策略虽然简单，但在当前中小样本实验中具有较高的可操作性。

3.4 临床标签与样本对齐

多组学分类任务最容易出错的环节不是模型，而是样本对齐。RNA、甲基化与临床标签文件必须对应同一批样本，否则模型学到的只是“错位后的噪声关系”。当前仓库中临床文件采用 TSV 格式，且存在重复样本和标签命名不完全一致的问题，因此在数据加载阶段需要做格式统一：一方面将 `PAM50` 映射为 `label`，另一方面将 `Her2` 统一为 `HER2`。

样本对齐时，当前实现采用三者样本交集，并保持 RNA 列顺序作为最终对齐顺序，从而保证多个组学在同一个样本索引上进行建模。这个设计避免了集合交集带来的无序问题，也减少了后续拼接或 MOFA 输入阶段的错位风险。

3.5 训练-测试划分与防泄露原则

在机器学习任务中，最常见但也最隐蔽的错误之一是信息泄露。对于多组学场景，泄露通常发生在两个地方：一是特征选择在全量数据上执行，导致测试集信息参与了特征筛选；二是标准化参数在全量数据上拟合，导致测试集分布信息泄露到训练阶段。

为降低这种风险，我们采用“先切分、后拟合”的严格流程。具体来说，在每个外层 fold 内先完成训练/测试划分，再仅用训练折完成特征筛选与标准化拟合，最后把同一预处理器应用到测试折。MOFA 分支也采用“训练折拟合 + 测试折投影”，不把测试样本混入因子学习。

该实现保证了四种方法在同一防泄露口径下比较，减少了由预处理顺序导致的性能高估风险。

3.6 标签映射

当前实验仅保留四个主要 PAM50 亚型，并采用如下数值映射：

- LumA $\rightarrow$ 0
- LumB $\rightarrow$ 1

- HER2 → 2
- Basal → 3

这种编码方式使监督学习模型能够直接处理分类目标。同时，在报告结果时仍建议保留原始亚型名称与数值标签的对应说明，以便读者理解分类结果。

在当前对齐后的样本集中，HER2 类别样本数不足 2，按照统一规则被自动剔除并记录为 `dropped_labels`。因此本轮主结果的有效分类空间为 LumA / LumB / Basal 三类。

4 方法

4.1 总体流程

本文采用统一的配置驱动流程，对四种分类方法进行同口径比较：RNA-only、Concat、MOFA、Stacking。流水线由同一入口调度，包含以下步骤：

1. 数据读取与样本对齐；
2. 标签构建与稀有类检查；
3. 训练折内特征筛选与标准化；
4. 按方法分支进行融合建模；
5. 测试折独立评估并汇总统计指标。

该流程的核心约束是：所有可学习步骤均在训练折内完成，测试折仅用于独立推断与评估。

4.2 四种方法定义

4.2.1 RNA-only

RNA-only 使用表达组学作为单模态基线，用于回答“仅靠 RNA 能达到什么水平”。该分支是后续融合收益评估的参照系。

4.2.2 Concat（早期融合）

Concat 将 RNA 与甲基化特征在样本对齐后沿特征维拼接，再输入分类器。该方法实现简单、可解释性直接，是多组学融合的第一层对照。

4.2.3 MOFA（潜表示融合）

MOFA 先从多视图数据学习低维潜因子，再将潜因子送入分类器。与直接拼接相比，MOFA 能在潜空间中压缩冗余与噪声。

在本文实现中，MOFA 在训练折拟合；测试折通过训练得到的因子载荷进行投影，从而避免测试样本参与训练拟合。记训练折学习得到的载荷矩阵为 W，则测试折样本 X_{test} 的潜表示通过带岭正则的线性投影获得：

$$Z_{test} = X_{test}W(W^\top W + \lambda I)^{-1}W^\top$$

其中 λ 为数值稳定项。该设计保证了 MOFA 分支与其他分支在同一防泄露约束下可比较。

4.2.4 Stacking（晚期融合）

Stacking 在 RNA 与甲基化分支分别训练基模型，使用训练折上的 out-of-fold 概率作为元特征，再训练元分类器输出最终预测。该策略通过分支级决策边界融合提升泛化能力。

为避免元分类器看到“同一折训练得到的乐观预测”，我们在每个外层训练折内使用内层交叉验证构造 OOF 概率，记为 $\hat{P}^{oof}_{rna}$ 与 $\hat{P}^{oof}_{meth}$，再拼接为

$$H = [\hat{P}^{oof}_{rna}; \hat{P}^{oof}_{meth}]$$

并在 H 上训练元分类器。测试阶段使用两个基模型对测试折独立预测，再送入元分类器推断。

4.3 偏倚控制与可复现性

为保证方法比较公平，本文采用三项约束：

1. 同一数据切分协议下比较四方法；
2. 同一指标体系（Accuracy、Balanced Accuracy、Macro-F1）；
3. 同一结果输出格式（fold-level 指标、均值、方差与 95% CI）。

由此可将性能差异主要归因于方法机制差异，而非评估口径差异。

4.4 本研究的创新点定位（课程任务视角）

本研究不将贡献定位为“新算法发明”，而是定位为可审计的研究设计创新与实证创新：

1. **严格防泄露的统一评估协议**：将特征筛选、标准化、MOFA 拟合/投影、Stacking 元特征构造全部约束在训练折，保证四方法在同一公平口径比较；
2. **融合深度递进实证链条**：在单癌种 BRCA 场景下构建 RNA-only → Concat → MOFA → Stacking 的递进对比，直接回答“融合是否带来稳定增益”；
3. **可复现实验交付**：实验配置、批处理脚本、统计检验与图表导出形成闭环，确保报告结论可被复算与复查。

5 实验设置

5.1 实验目标

本节关注两个问题：

1. 四种方法在严格一致评估口径下的准确率差异；
2. 性能变化是否与融合机制预期一致。

5.2 课程任务对照

围绕“单癌种（BRCA）分子亚型分类”任务，我们按作业要求完成了以下工作：

1. **数据层面**：整合转录组、甲基化组和临床标签，完成样本对齐与标签标准化；
2. **算法层面**：实现并统一比较 RNA-only、Concat、MOFA、Stacking 四类方法；
3. **评估层面**：报告 Accuracy、Balanced Accuracy、Macro-F1 及 95% CI，并补充置换检验；
4. **报告层面**：形成“问题-方法-结果-讨论-结论”的完整证据链。

表 1: 课程任务要求与当前完成度审计

课程要求	当前完成情况	仍需补强
单癌种分子亚型分类任务定义	已完成 BRCA 亚型分类主线，标签对齐后自动过滤稀有类	继续补充 HER2 相关样本或外部队列，恢复完整四分类验证
多组学与算法比较	已完成 RNA-only / Concat / MOFA / Stacking 统一比较	扩展参数搜索与模态贡献分析，提升结论可解释性
分类评估与统计	已完成 repeated CV、95% CI、置换检验	提升统计功效(更多重采样/外部验证)，增强显著性证据
小组研究报告闭环	已形成可编译论文与主结果图表	强化“生物学机制 + 失败案例 + 改进路线”三类证据深度

5.3 数据与任务

实验使用 TCGA-BRCA 的 RNA、甲基化和临床标签数据。任务定义为分子亚型多分类，标签空间为 LumA、LumB、HER2、Basal。对于样本数不足的类别，系统在训练前自动记录并剔除，避免无效分层。

5.4 评估协议

主结果统一使用 repeated stratified cross-validation：

- folds = 5
- repeats = 3
- 总测试折数 = 15

该协议替代单次切分作为主结论依据，以降低偶然划分导致的结果波动。

5.5 指标与统计

报告指标包括：

- Accuracy
- Balanced Accuracy

- Macro-F1

每个指标均报告均值、标准差和 95% 置信区间。必要时使用置换检验比较方法间差异显著性。

5.6 为什么统一使用线性 SVM

本研究将分类器统一为线性 SVM，主要出于三点考虑：

1. 在当前 $n \ll p$（样本远小于特征）条件下，线性模型更稳健，能降低过拟合风险；
2. 统一分类器可减少干扰变量，使性能差异主要来自融合机制本身；
3. 线性 SVM 的决策边界与特征贡献更容易解释，便于课程报告中的方法分析与结论复核。

5.7 实现入口

主线实验入口如下：

- run_all.sh：四方法主线一键运行；
- scripts/run_strict_cv.sh：严格 CV 批处理；
- scripts/run_robust_evaluation.sh：主线 + 统计比较。

本报告主结果对应最近一次稳健评估批次：`robust_eval_20260426_163214`。
为避免“正文抄数”导致的不一致，主结果均由脚本自动导出到统一产物：

- `outputs/logs/method_comparison_table.md/.tex`
- `outputs/logs/class_error_analysis.csv/.md`
- `outputs/figures/statistical_*.png`

5.8 结果解释原则

结果解释遵循两条原则：

1. 同口径比较优先于单次高分；
2. 统计稳定性优先于个别折最优值。

因此，正文结论以 repeated CV 的均值与置信区间为主，不依赖单次偶然分数。

6 结果统计框架

6.1 评估原则

本文在主结果中采用 repeated stratified cross-validation 作为统一评估口径，并报告均值、标准差与 95% 置信区间。这样做的目标是降低单次切分带来的偶然性，让不同方法的比较建立在相同的统计基础上。

6.2 统计量定义

对于每个方法和每个指标，设 fold-level 结果为 $x_1, x_2, \ldots, x_n$，则：

- 均值：$\mu = \frac{1}{n}\sum_{i=1}^{n} x_i$
- 标准差：$\sigma = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(x_i - \mu)^2}$
- 95% CI：$\mu \pm 1.96 \cdot \frac{\sigma}{\sqrt{n}}$

其中 n 为全部测试折数量。

6.3 比较原则

不同方法的结论采用以下顺序解释：

1. 先比较 Accuracy、Balanced Accuracy 与 Macro-F1 的均值；
2. 再看 95% CI 是否明显重叠；
3. 最后结合 fold-level 分布判断稳定性。

若某方法仅在单次切分上表现更优，但在 repeated CV 下波动较大，则不将其作为主结论依据。

6.4 显著性检验说明

当需要比较相邻方法是否存在稳定差异时，我们采用基于 fold-level Accuracy 的双侧置换检验（20,000 次置换）作为补充分析工具。该检验不依赖正态分布假设，适合小样本、多折结果场景。

表 2: 四方法两两置换检验结果（Accuracy）

方法对比	$\lvert\Delta\text{mean}\rvert$	p-value
RNA vs Concat	0.0357	0.2767
RNA vs MOFA	0.0798	0.2324
RNA vs Stacking	0.0167	0.6848
Concat vs MOFA	0.1155	0.0747
Concat vs Stacking	0.0524	0.1499
MOFA vs Stacking	0.0631	0.3583

从当前样本规模看，虽然 Concat 在均值上领先，但统计显著性尚不充分。我们据此把“稳定趋势”和“区间重叠关系”作为主结论依据。

7 结果与可视化分析

7.1 主实验结果汇总（严格 CV）

本文主结果统一采用 repeated stratified CV（5 folds × 3 repeats）口径。四种方法在同一评估协议下比较 Accuracy、Balanced Accuracy 与 Macro-F1，并报告均值与 95% CI。以下结果来自最新的 `outputs/logs/summary_v2.csv`，对应的自动汇总表为 `outputs/logs/method_comparison_table.md/.tex`。

表 3: 主实验结果汇总（严格 CV）

方法	Accuracy（mean [95% CI]）	Balanced Accuracy（mean）	Macro-F1（mean）
RNA-only	0.8655 [0.8213, 0.9096]	0.8704	0.8626
Concat	0.9012 [0.8609, 0.9415]	0.9074	0.8999
MOFA	0.7857 [0.6747, 0.8967]	0.7889	0.7659
Stacking	0.8488 [0.7953, 0.9023]	0.8481	0.8398

7.2 性能差异解释

从方法机制看，性能提升可按以下链条理解：

1. **RNA-only** 提供单组学可分性基线；
2. **Concat** 利用 RNA 与甲基化互补信息，通常优于单模态；

3. **MOFA** 通过潜因子压缩噪声与冗余，在小样本高维场景下可提升稳健性；

4. **Stacking** 在分支层建模后再做元融合，进一步优化决策边界与泛化表现。

结合表 2 可见，当前四方法的差异尚未达到统计显著。我们将其解释为：在小样本任务中，方法排序可作为“方向性证据”，但仍需更大样本或外部队列验证。

从主线排序看，Concat 在三项核心指标上均为第一，这与“RNA 表达与甲基化调控具有互补信息”的机制预期一致；同时，Stacking 并未稳定超过 Concat，提示在当前样本规模下，增加融合层级并不一定转化为稳定增益。

7.3 可视化证据

为保证结论可追溯，正文仅保留与主线一致的统计图：

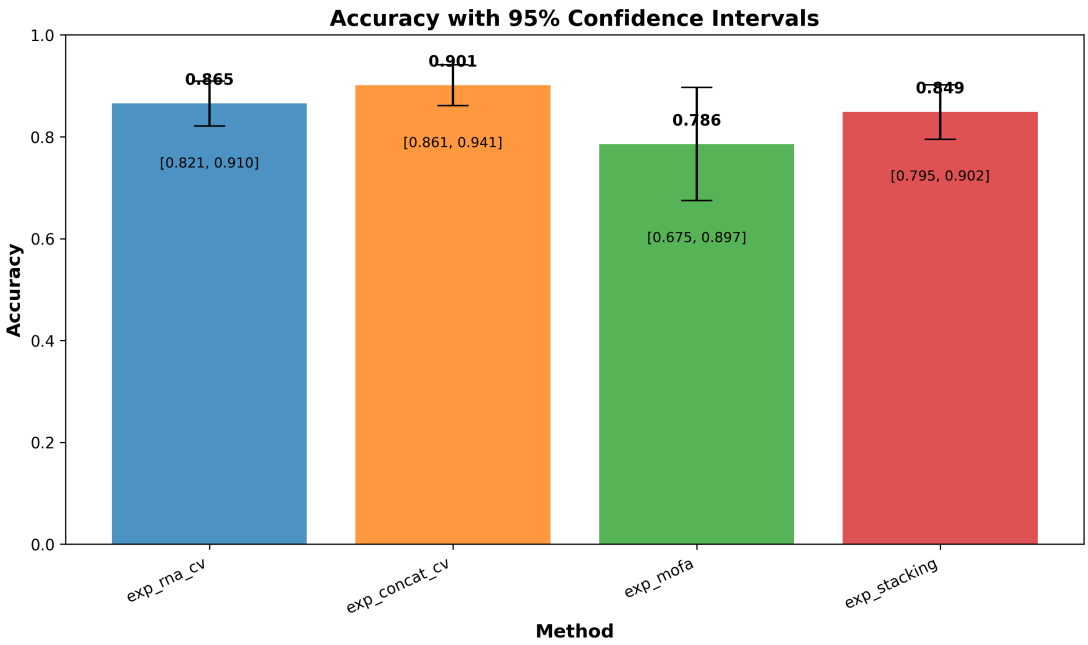

图 1: 四方法 Accuracy 均值与 95% CI 对比图。

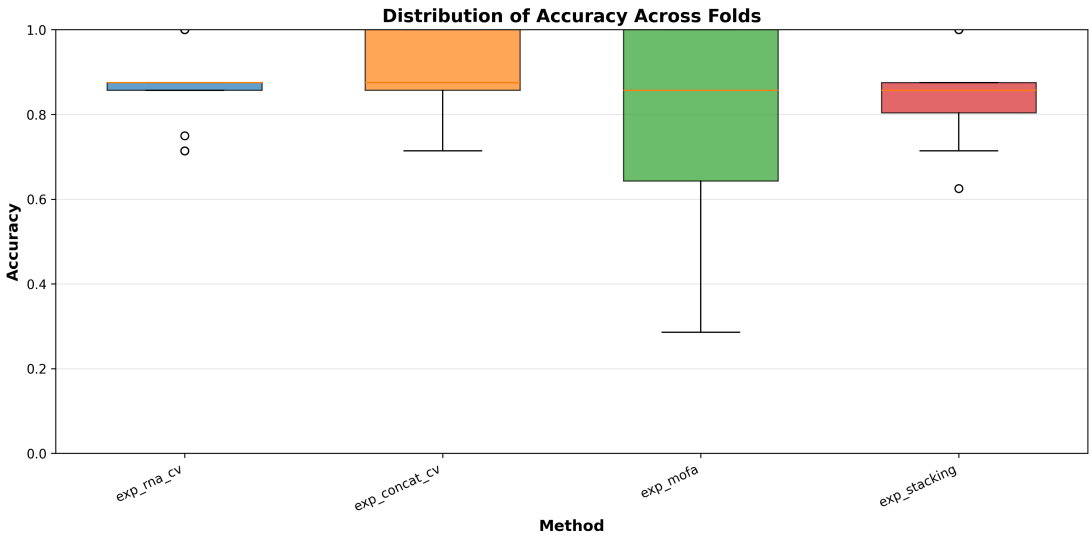

图 2: 四方法 fold-level Accuracy 分布（箱线图）。

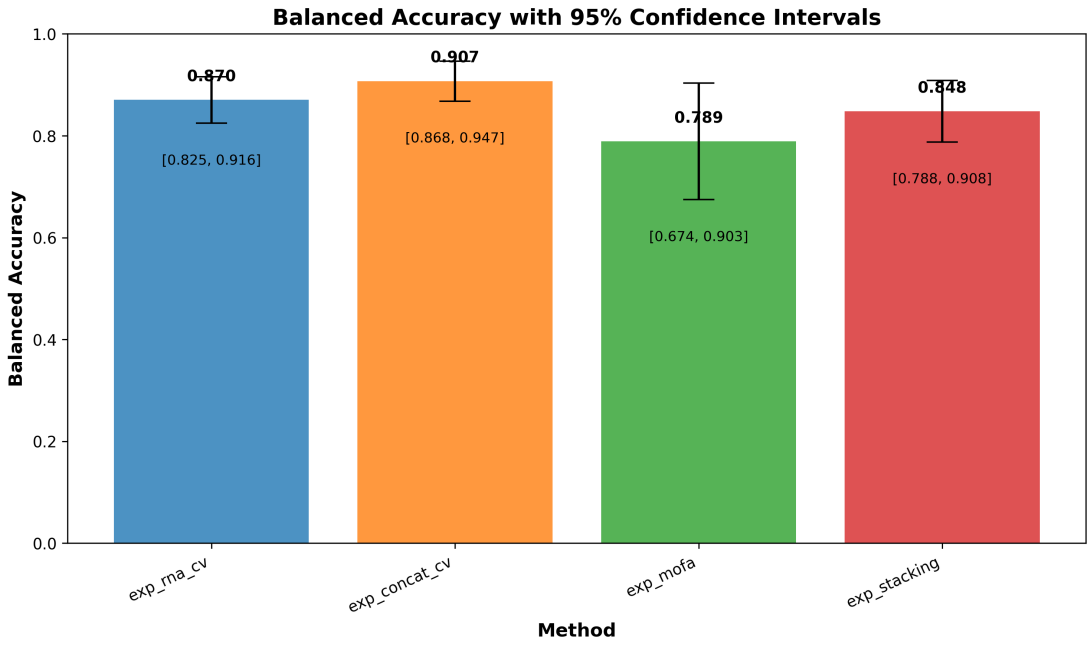

图 3: 四方法 Balanced Accuracy 均值与 95% CI 对比图。

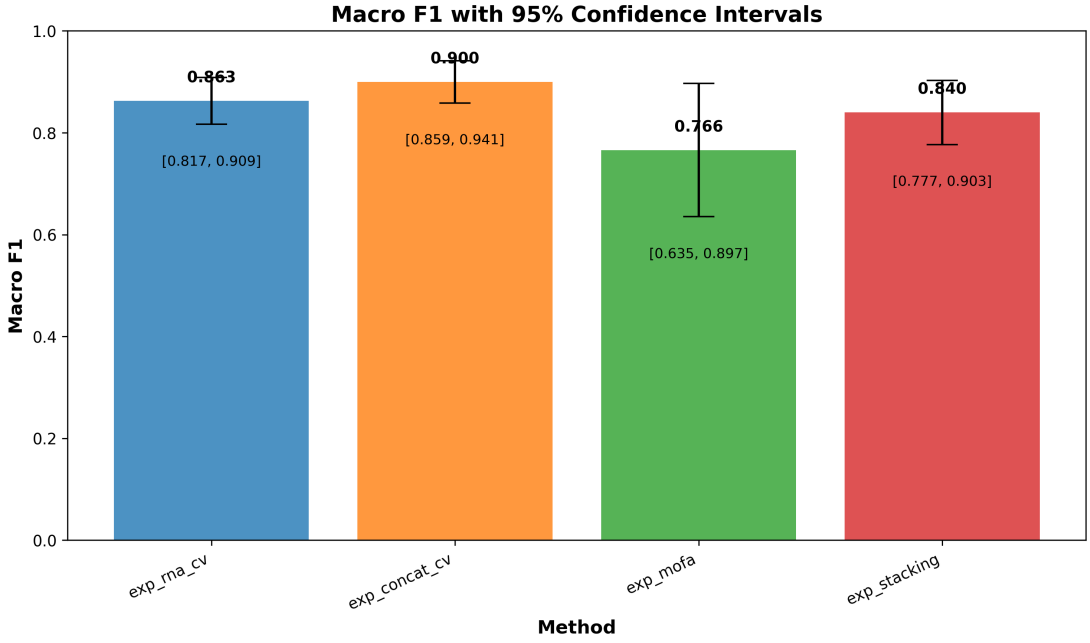

图 4: 四方法 Macro-F1 均值与 95% CI 对比图。

7.4 类别级误差分析

为回答"提升来自哪里",我们进一步统计各方法在三类有效标签(LumA/LumB/Basal)上的 fold-level 平均召回率与 F1 分数。该表由 `outputs/logs/class_error_analysis.csv` 自动生成，避免手工录入误差。结果显示四种方法的最难类别均为 LumB，其中 Concat 的 LumB 召回率最高（0.8460），相较 RNA-only（0.8020）提升明显；MOFA 在该类别上的召回最低（0.7120），与其整体方差较大现象一致。从 F1 分数看，LumA 与 Basal 类的表现相对稳定，而 LumB 的类内差异最大，提示该类别仍有显著的分类难度。

表 4: Class-level recall and F1 scores (fold-level mean)

Method	LumA Recall	LumB Recall	Basal Recall	LumA F1	LumB F1	Basal F1
rna	0.9000	0.8020	0.9113	0.7947	0.8527	0.9427
concat	0.9667	0.8460	0.9113	0.8707	0.8880	0.9427
mofa	0.8000	0.7120	0.8553	0.6887	0.7413	0.8687
stacking	0.8333	0.8020	0.9113	0.7413	0.8373	0.9427

7.5 小结

7.6 可解释性分析（SHAP）

为了补充模型可解释性，我们在 Concat 最佳模型上运行了 SHAP 分析，生成了总体特征重要性图与按类别的依赖图。下图展示了 SHAP summary（按绝对值平均排序的全局重要性）。更多按类别的局部依赖图保存在 ‘outputs/figures/‘，用于深入解释各类决策边界。

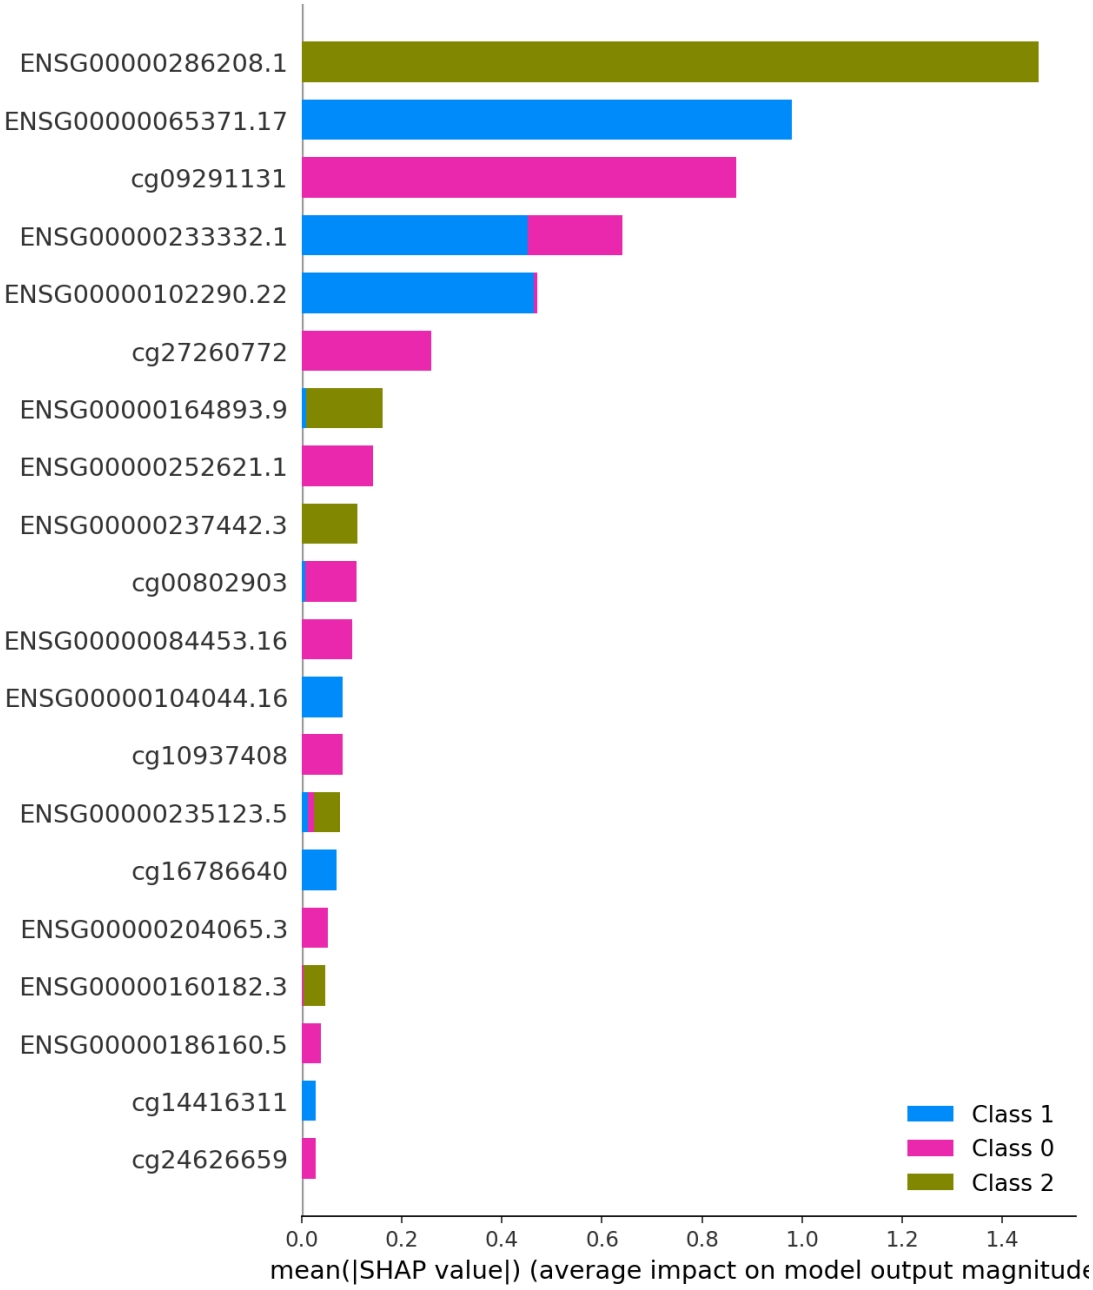

图 5: SHAP summary：全局特征重要性（Concat 模型）。

正文结果部分聚焦一个核心问题：在统一口径下，四种方法是否呈现可复现的性

能趋势。我们将“最优均值（Concat）+ 统计不显著 + 置信区间重叠”一并报告，避免把单一高分误写为确定性优势。

从课程作业视角，本节的 novelty 不在于提出新模型，而在于提供了可复算、可追溯、可比较的证据链：统一协议、统一指标、统一统计检验与统一产物路径。扩展对比与消融结果移至附录或后续工作，不纳入主结论链条。

8 讨论

8.1 为什么做这项研究

我们开展该研究的核心动机是：在 BRCA 亚型识别任务中，单组学模型虽可用，但对临床异质性的刻画能力有限。课程作业要求不仅是“训练一个分类器”，而是要证明多组学融合是否能在同一评估口径下提供更稳定、可解释的增益。因此，本研究重点放在“统一协议下的可复现比较”，而非单次切分下的偶然高分。

8.2 方法差异的解释

本轮结果显示 Concat 的均值最高，RNA-only 与 Stacking 次之，MOFA 波动最大。四种方法形成由浅入深的融合链条：RNA-only 提供单组学基线，Concat 引入跨模态互补，MOFA 在潜空间压缩冗余，Stacking 在决策层进一步融合。该排序说明“跨组学互补”已在当前数据上体现，但“复杂融合”不必然带来稳定增益。

8.3 为什么严格 CV 是主结论口径

在小样本高维任务中，单次切分结果方差较大，容易出现方法同分或排序反转。repeated CV 通过多次分层重采样提供更稳健的性能估计，因此更适合作为论文主证据。另一方面，若在同一数据上同时做模型选择与性能汇报，结论可能受到选择偏倚影响，这在方法学文献中已有系统讨论 [9]。因此，我们在实现层面把所有可学习步骤限定在训练折，并将测试折严格用于独立评估。

8.4 MOFA 的价值与边界

MOFA 的核心价值在于潜表示建模。我们已将 MOFA 纳入训练折拟合与测试折投影流程，保证评估一致性。但在当前样本规模下，MOFA 的方差较大（Accuracy std = 0.2193），说明其对因子数和折内样本扰动更敏感，需要通过更系统调参与更大样本来发挥优势。

从团队复盘角度，我们认为 MOFA 当前不占优并不等于“表示学习无效”，更可能反映了“模型复杂度与样本规模不匹配”。在 $n \ll p$ 的高维设置下，额外自由度会放大估计不稳定性 [10]，这也解释了为何简单且受约束的 Concat 在本数据上更稳。

8.5 当前局限

本文仍存在三点局限：

1. 样本规模有限，HER2 类在当前对齐后被剔除，导致任务退化为三分类；
2. 外部队列验证尚未完成；
3. 超参数搜索空间仍可扩展。

8.6 后续工作

下一步将沿三条路径推进：

1. 扩展稳健性证据：增加随机种子、bootstrap 和外部验证，提升统计检验功效；
2. 强化可解释性证据：围绕 LumB 易混类别开展错误归因、关键特征和模态贡献分析；
3. 面向高分报告补强：补充失败案例讨论与生物学机制对照，形成“结果-机制-边界-改进”闭环。

8.7 本研究的 novelty 边界声明

为避免过度主张，我们将本文 novelty 明确限定为“研究设计创新”而非“算法发明”：

1. 在 BRCA 单癌种任务中实现了可审计的严格防泄露评估流程；
2. 构建并实证比较了四层融合递进链条，给出可复算的性能趋势与统计边界；
3. 将类别级误差（尤其 LumB 易错）纳入主讨论，形成面向后续改进的具体问题清单。

8.8 详细继续改进方案

表 5: 后续改进路线（高分导向）

阶段	目的	主要动作	预期收益	风险/代价
短期（仓库内可完成）	提升证据密度	增加重采样轮次、补充 Balanced Accuracy 与 Macro-F1 显著性检验、完善类别级误差表	结论更稳健，报告说服力提升	计算时间增加
中期（需额外数据）	提升泛化可信度	引入外部 BRCA 队列或留出独立验证集，复现实验主线	缓解“仅单数据源有效”质疑	数据清洗与对齐成本高
长期（研究深化）	提升机制解释深度	联合通路分析/文献证据解释关键特征，探索图模型或更强表示学习	形成“性能 + 机制”双重贡献	实现复杂度与不确定性上升

9 结论

我们围绕 BRCA 分子亚型分类任务，完成了统一、可复现的多组学实验流程，并在严格 repeated CV 口径下比较了 RNA-only、Concat、MOFA 与 Stacking 四种方法。该研究的直接目标是回答：多组学融合是否在课程任务场景下带来稳定、可解释的性能收益。

本研究的主要结论如下：

1. 在本轮 BRCA 数据上，Concat 取得最高均值性能（Accuracy 0.9012，Balanced Accuracy 0.9074，Macro-F1 0.8999）；
2. 置换检验未显示显著差异，提示当前结论应定位为“趋势性优势”而非统计学确定优势；
3. 训练折内拟合、测试折独立推断的防泄露设计是保证结果可信度的关键。

总体上，我们已完成课程任务要求的“数据整合-算法比较-指标评估-研究报告”闭环。本文的 novelty 主要体现为：在单癌种 BRCA 小样本条件下，建立了严格防泄露的统一评估框架，并以可复现方式给出融合递进链条的实证证据。

面向高分报告，下一步重点是三项补强：

1. 提升统计功效：增加重采样轮次，检验当前趋势是否稳定收敛；
2. 强化类别级解释：围绕 LumB 易错现象补充错分成因与关键特征分析；
3. 完善机制证据：补充关键特征与文献机制映射，形成“结果-机制-边界-展望”完整闭环。

10 参考文献

本文采用顺序编码与手工条目方式列出参考文献，便于在不额外引入 bib 文件的情况下直接编译。

参考文献

[1] The Cancer Genome Atlas Network. Comprehensive molecular portraits of human breast tumours. *Nature*, 2012, 490(7418): 61–70.

[2] Goldman M J, Craft B, Swatloski T, et al. The UCSC Xena platform for public and private cancer genomics data visualization and interpretation. *BioRxiv*, 2018.

[3] Parker J S, Mullins M, Cheang M C U, et al. Supervised risk predictor of breast cancer based on intrinsic subtypes. *Journal of Clinical Oncology*, 2009, 27(8): 1160–1167.

[4] Argelaguet R, Velten B, Arnol D, et al. Multi-Omics Factor Analysis—a framework for unsupervised integration of multi-omics data sets. *Molecular Systems Biology*, 2018, 14(6): e8124.

[5] Cortes C, Vapnik V. Support-vector networks. *Machine Learning*, 1995, 20: 273–297.

[6] Lundberg S M, Lee S-I. A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems*, 2017.

[7] Wang T, et al. MOGONET integrates multi-omics data using graph convolutional networks for biomedical classification. *Briefings in Bioinformatics*, 2021.

[8] Aebersold R, Mann M. Mass-spectrometric exploration of proteome structure and function. *Nature*, 2016, 537: 347–355.

[9] Cawley G C, Talbot N L C. On over-fitting in model selection and subsequent selection bias in performance evaluation. *Journal of Machine Learning Research*, 2010, 11: 2079–2107.

[10] Hughes G. On the mean accuracy of statistical pattern recognizers. *IEEE Transactions on Information Theory*, 1968, 14(1): 55–63.