福州大学
FUZHOU UNIVERSITY

医工交叉研究院
INTERDISCIPLINARY INSTITUTE FOR MEDICAL ENGINEERING

第四章 多组学分析-转录组学

5. 基于多组学数据的疾病分类

明德至诚 博学远志

疾病分类的常见任务

pan-cancer 多分类，即区分不同癌种。例如对BRCA、LUAD等多种癌症进行分类。

单癌种内部的分子亚型分类。例如在 BRCA、LUAD、LIHC 内部分亚型。

诊断性二分类/多分类。如BRCA的肿瘤与非肿瘤。

差异表达分析

疾病分类的常见方法

□ 传统机器学习

这是 TCGA 多组学分类最稳妥、最容易复现的一类路线。典型做法是先对各组学分别做特征筛选或降维，再把特征拼接或分层融合，最后用 SVM、Random Forest、XGBoost、Elastic Net、逻辑回归 等分类器建模。

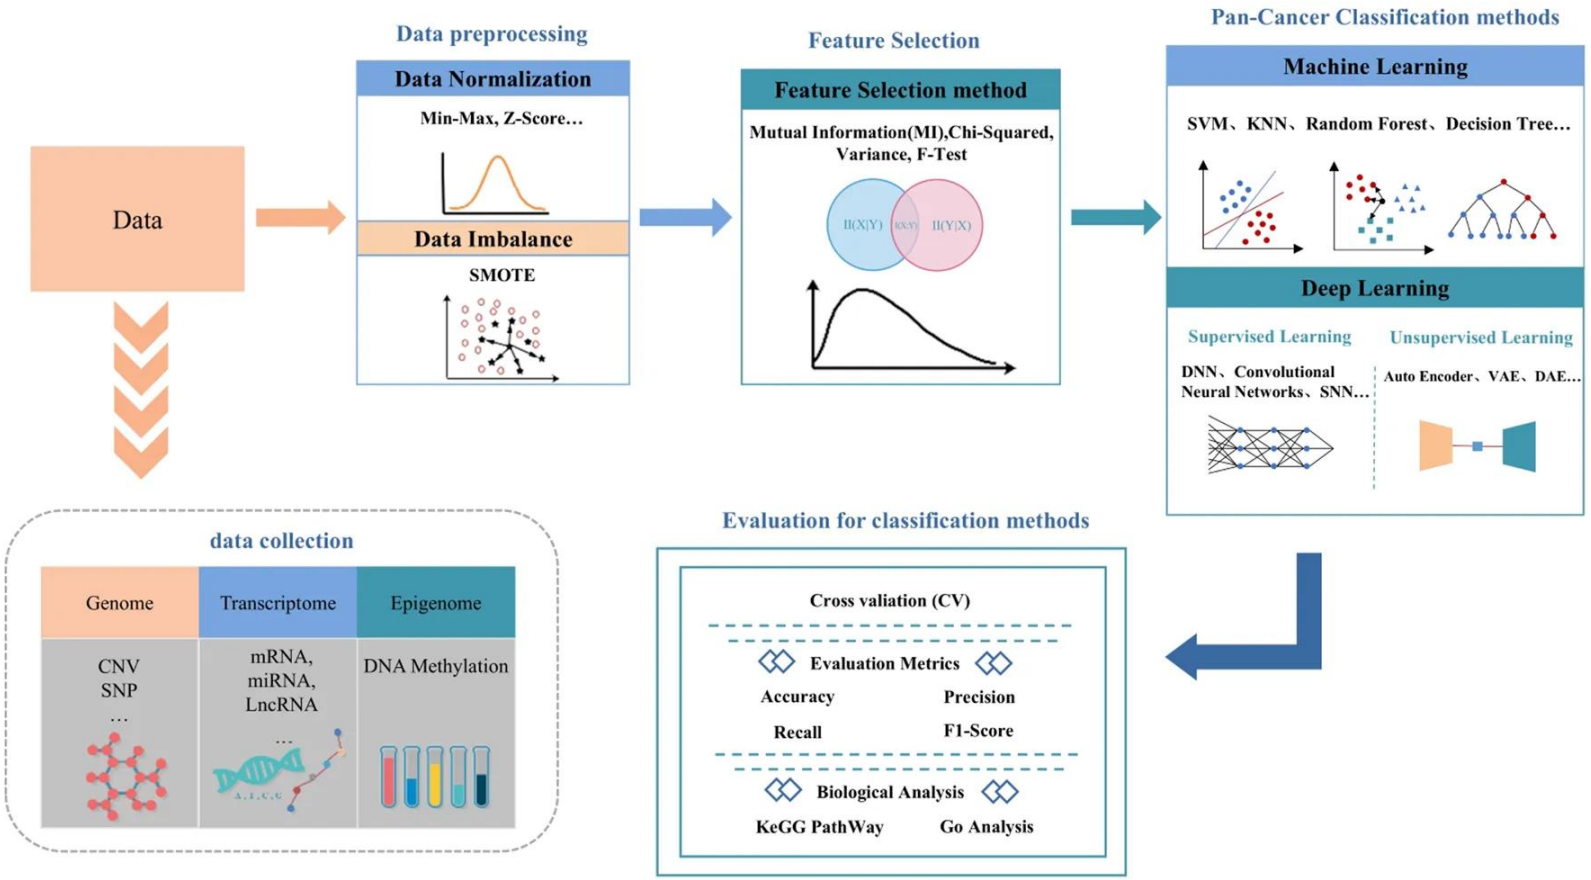

它的优势是对中小样本、高维数据更稳，解释也相对直接；劣势是对跨组学非线性关系的建模能力有限。

差异表达分析

疾病分类的常见方法

- **表示学习 / 深度学习**

这类方法先为每种组学学习低维表示，再做分类，核心代表是 Autoencoder、Variational Autoencoder (VAE)、多分支 MLP/CNN。

MOFA/MOFA+ 更偏统计表示学习与可解释降维，适合先找潜在因子、再接下游分类；XOmiVAE 是偏可解释的 VAE 分类模型；还有研究直接用 VAE/MMD-VAE 对 TCGA 卵巢癌等多组学数据做样本识别、亚型聚类和分类。

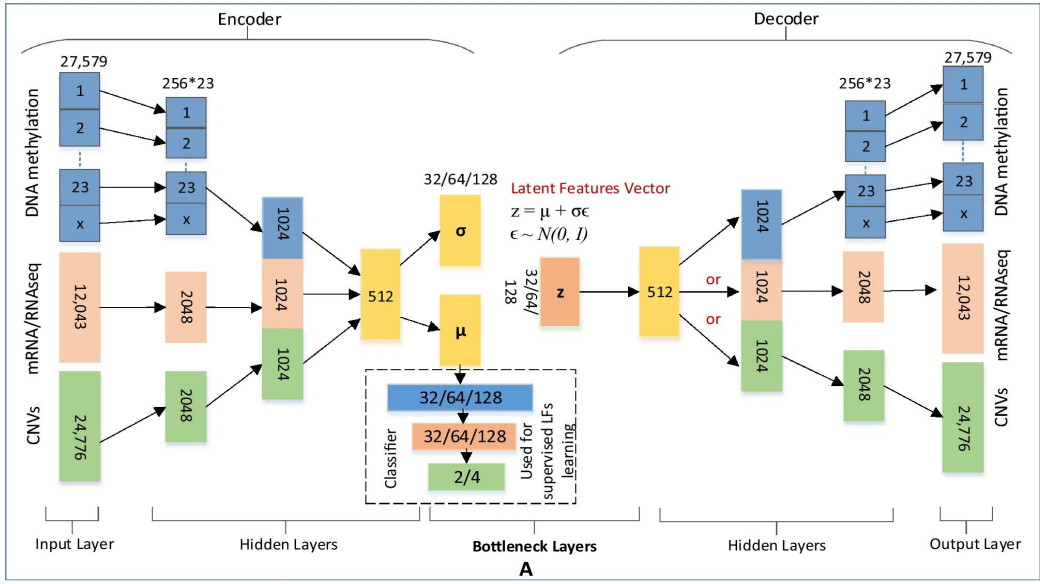

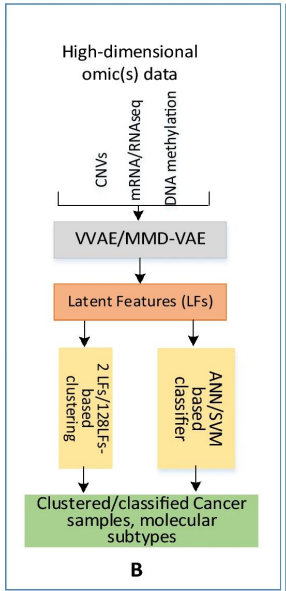

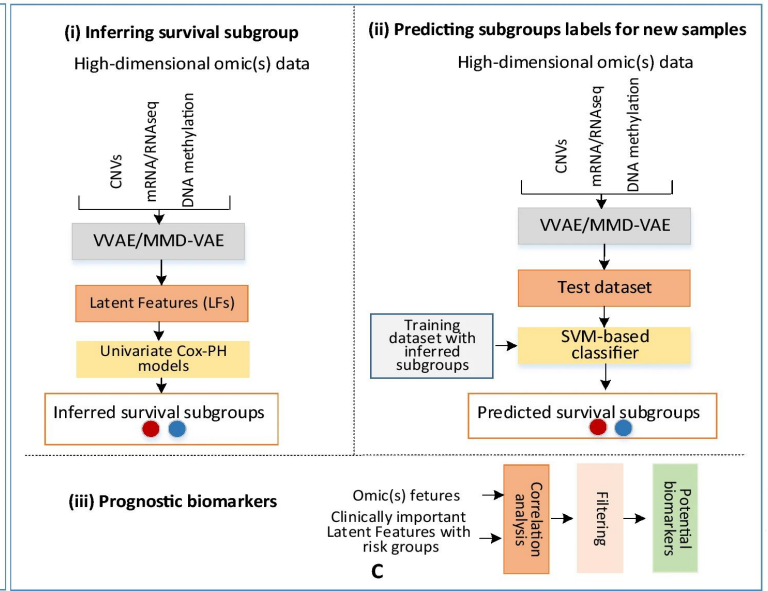

差异表达分析

疾病分类的常见方法

□ 图机器学习 / 图神经网络

多组学数据天然带有“关系结构”：基因—基因、蛋白—蛋白、患者—患者、通路—通路之间都不是独立的。

代表性方法里，MOGONET 很典型：它用图卷积网络整合多组学，用于生物医学分类任务，并兼顾生物标志物识别；近两年也出现了更多 multi-view GNN、graph attention、hierarchical GNN 变体，重点解决多模态关系建模和解释性问题。

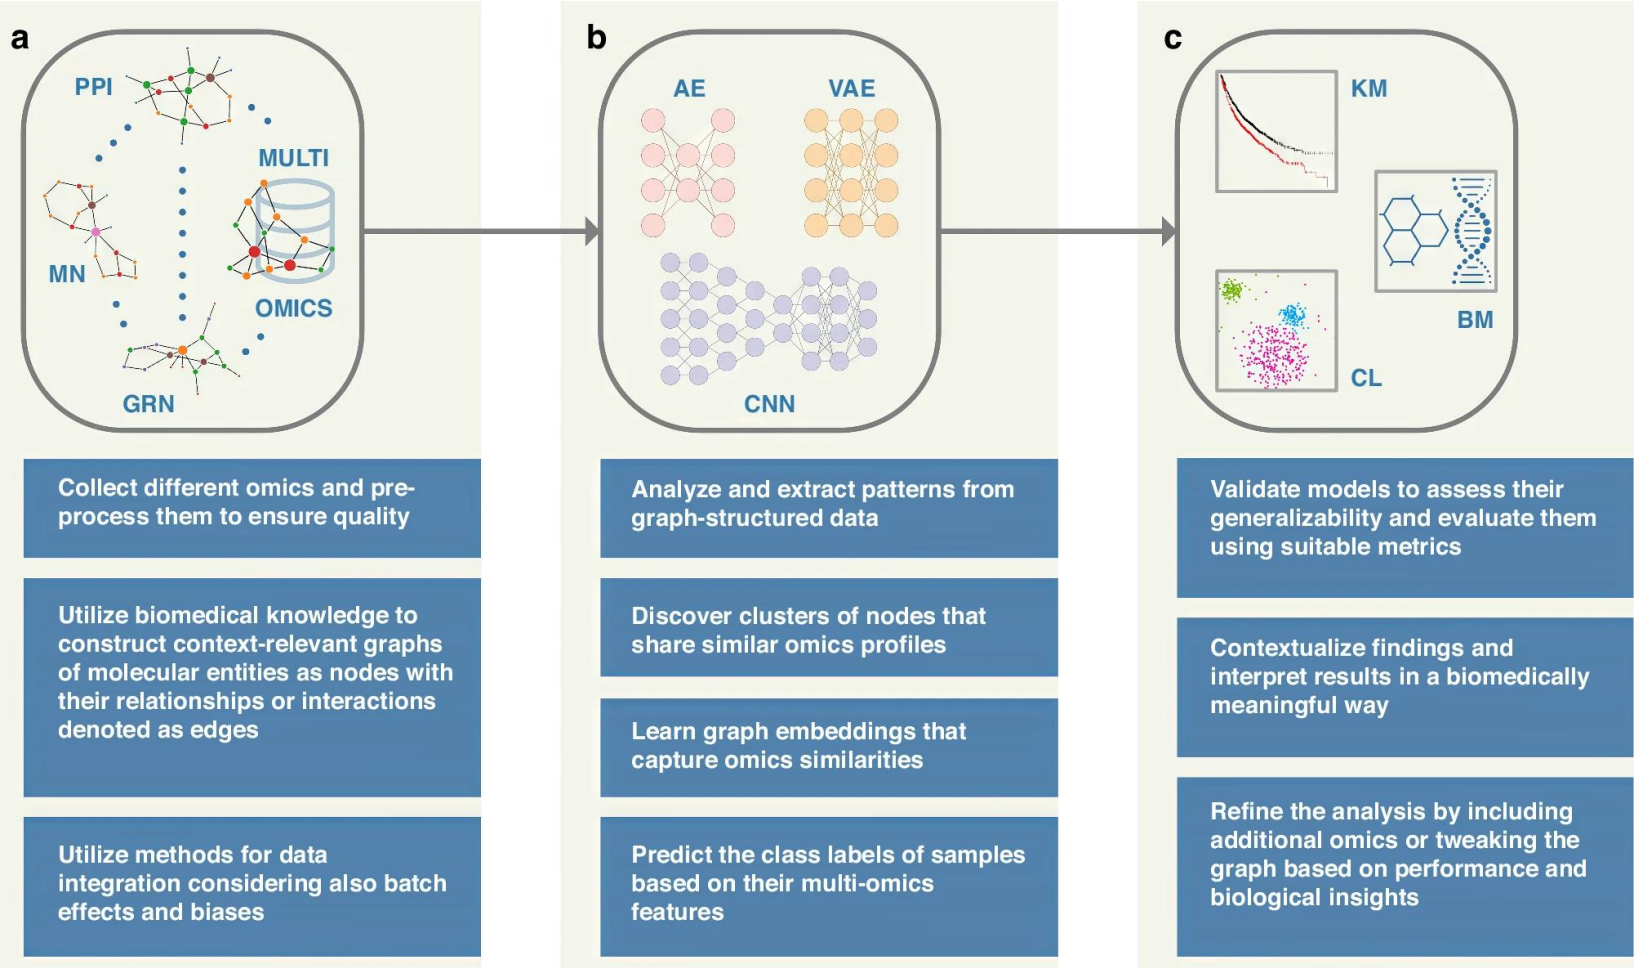

差异表达分析

疾病分类的常见方法

◻ 更广义的“AI”方法

对比学习、自监督预训练、迁移学习、生成式模型、foundation-model 风格的表征学习。

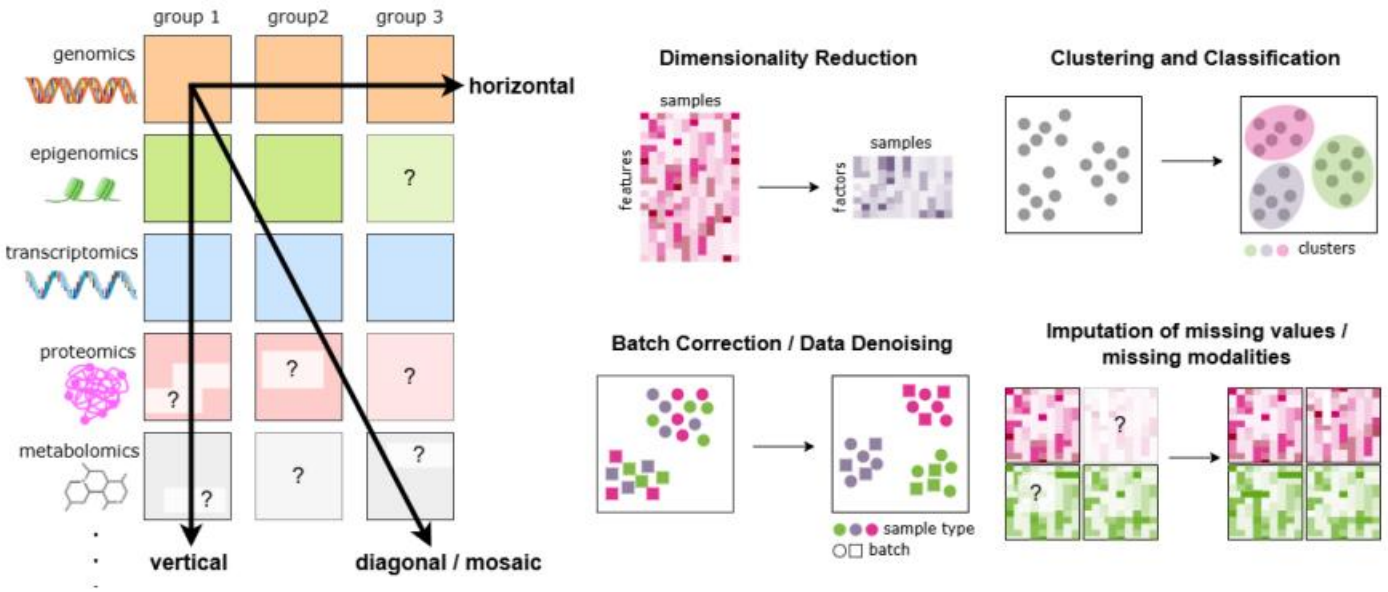

基于多组学数据的疾病分类

TCGA简介

◆ 肿瘤基因组图谱 (The Cancer Genome Atlas, TCGA)计划由美国 National Cancer Institute(NCI) 和 National Human Genome Research Institute (NHGRI) 于2006年联合启动。目前收录了来自 11,000 个病人，33个癌症的数据，2.5P的数据量。

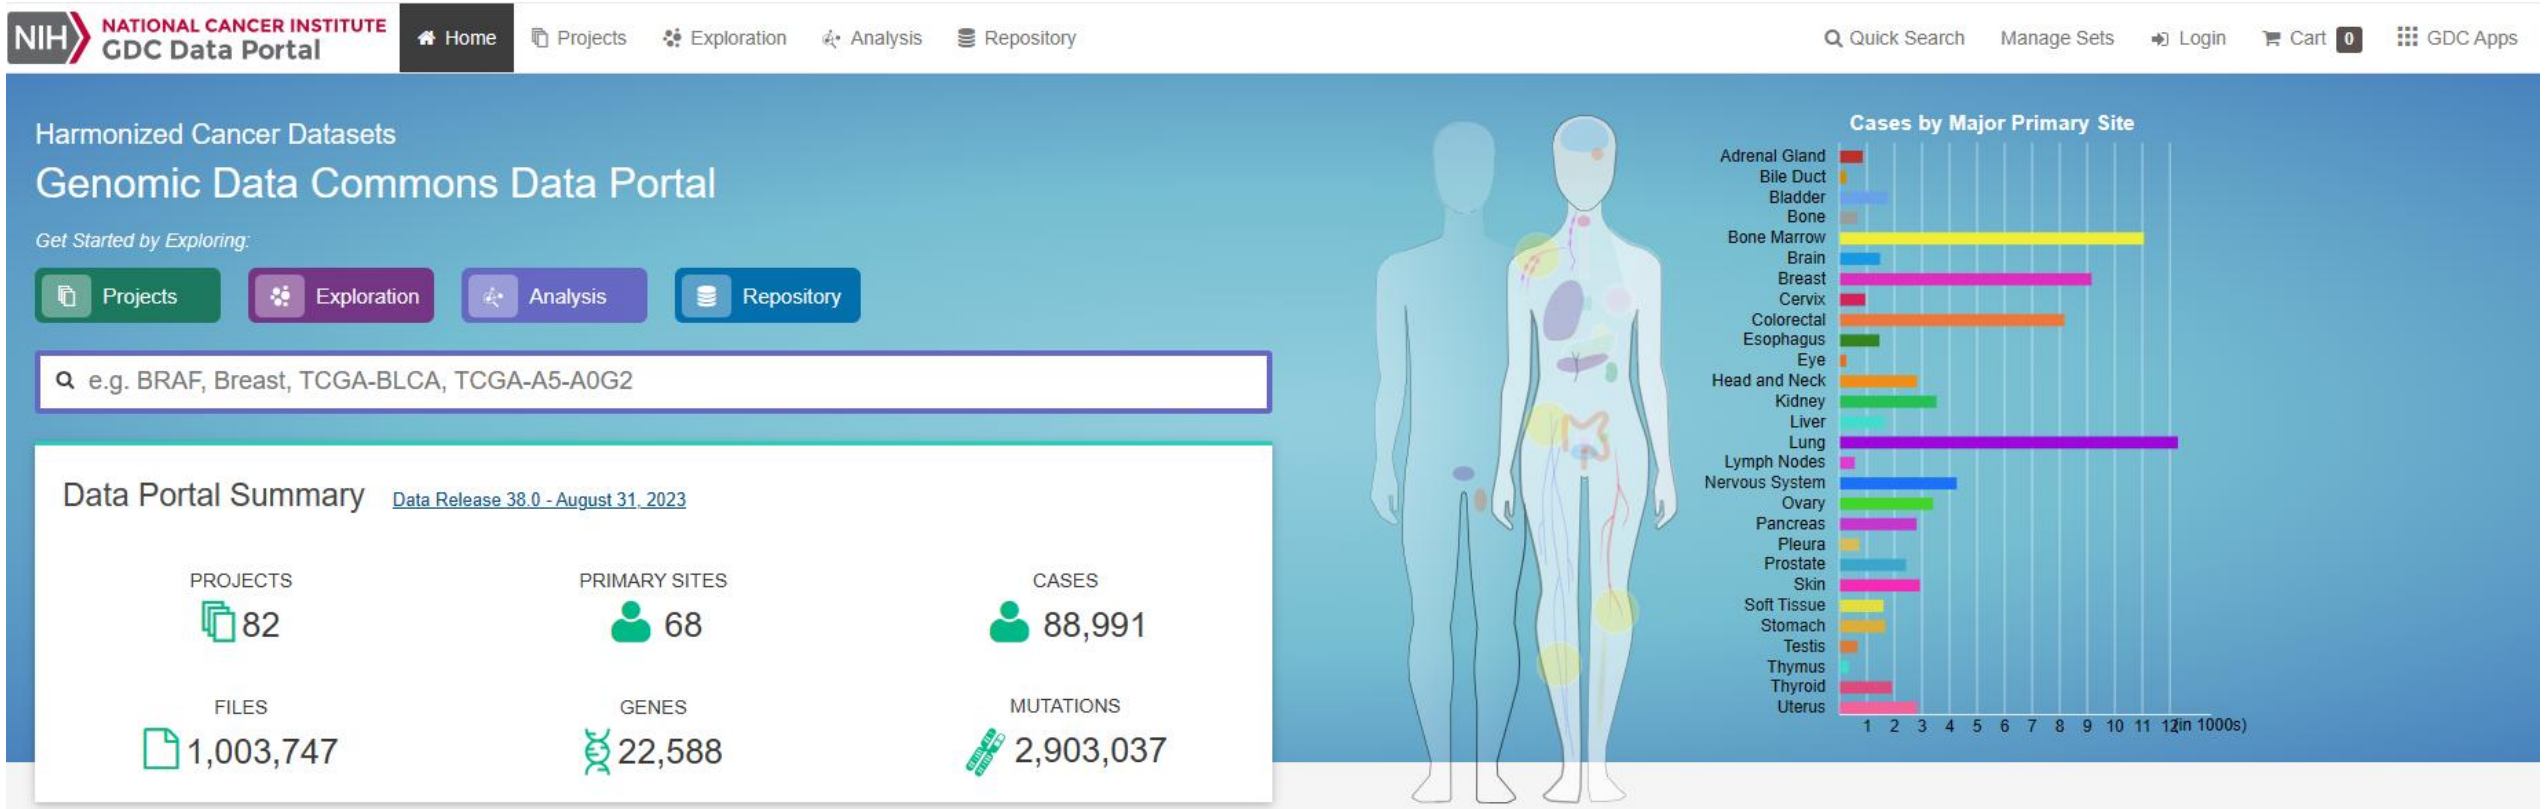

TCGA数据下载——UCSC Xena

Explore TCGA, GDC, and other public cancer genomics resources

Mary Goldman · 6 March 2019

Discover new trends and validate your findings with 1500+ datasets and 50+ cancer types.

We provide interactive online visualization of seminal cancer genomics datasets, including data from The Cancer Genome Atlas (TCGA), International Cancer Genome Consortium (ICGC), and Genomic Data Commons (GDC). We also visualize the UCSC RNA-seq compendium which contains data from TCGA tumor samples, TCGA normal samples, and GTEx normal samples.

Xena supports virtually any functional genomics data, including SNVs, INDELs, large structural variants, copy number variation, gene-, transcript-, exon-, miRNA-, LncRNA-, protein-expressions, DNA methylation, ATAC-seq signals, phenotypic/clinical annotations, and higher-level derived genomic parameters.

Learn More about the public data we host

Launch Xena

- UCSC Xena中不仅包含TCGA数据，还包含ICGC、CCLE等其他数据资源。
- https://xena.ucsc.edu/public/
- 通过“Launch Xena”进入数据下载页面

TCGA数据下载——UCSC Xena

◆ 选择数据中心和癌症类型

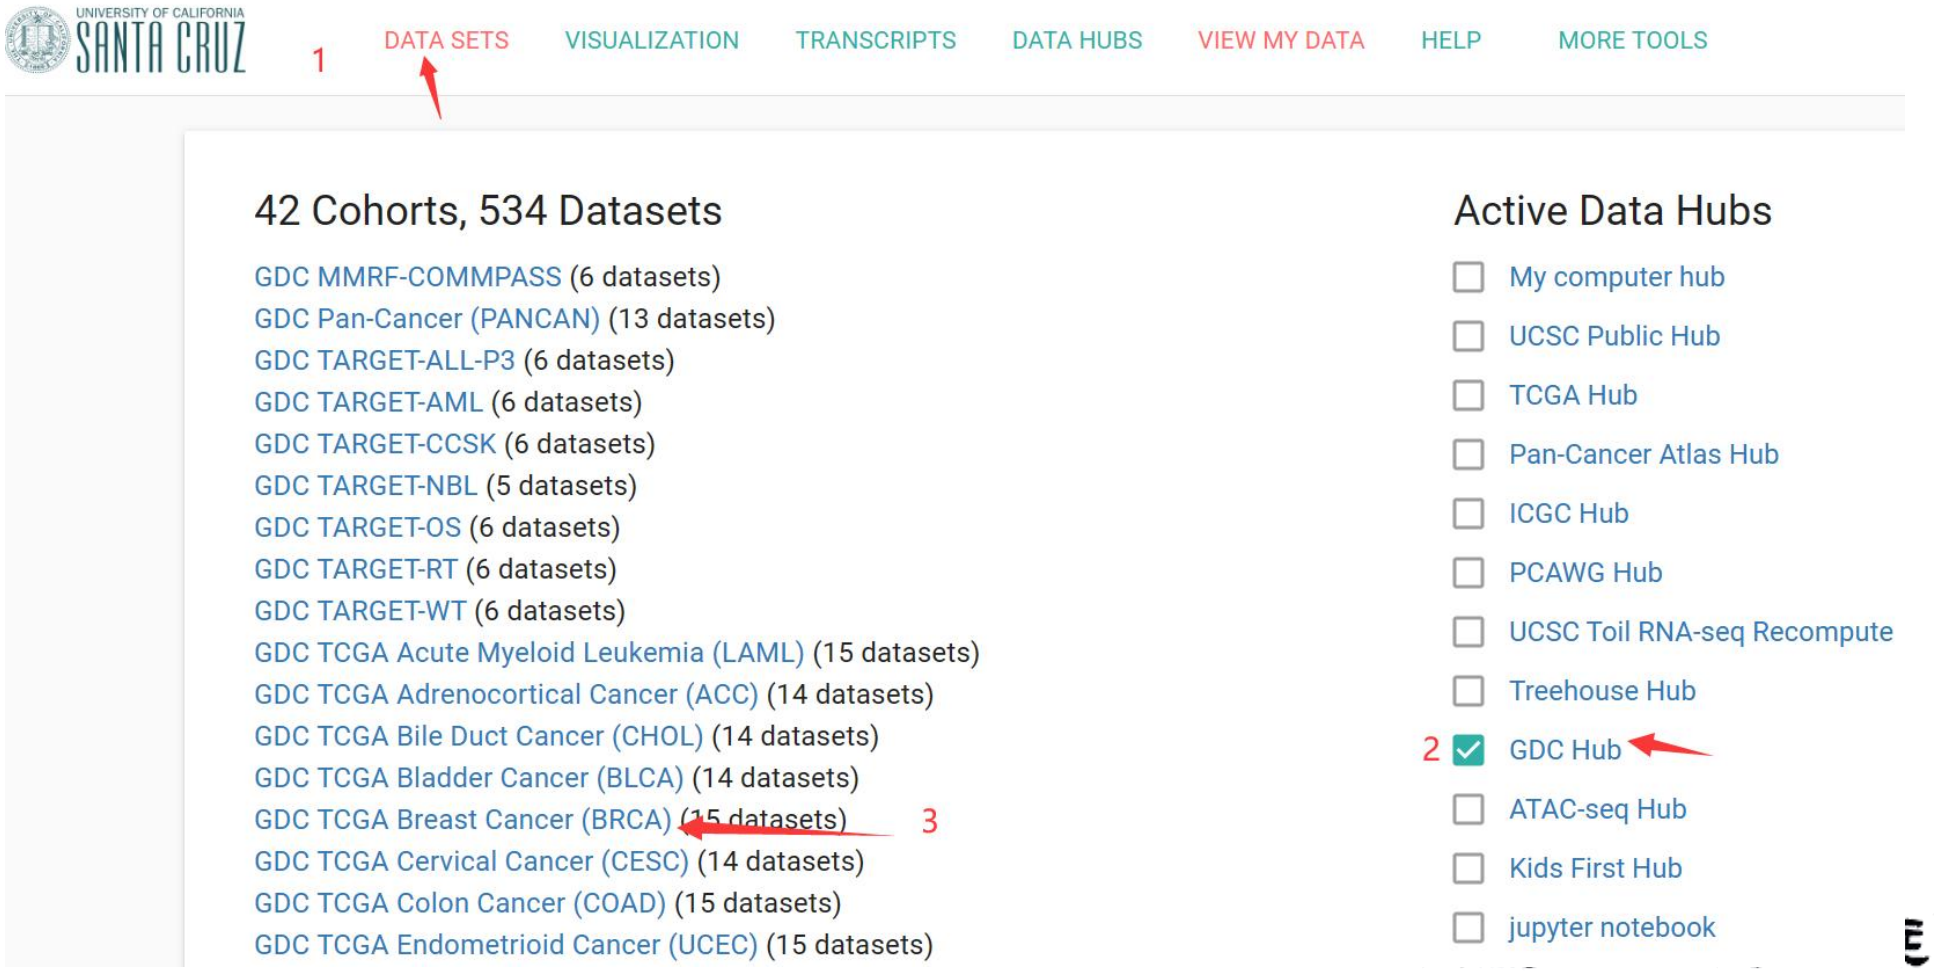

基于多组学数据的疾病分类

cohort: GDC TCGA Breast Cancer (BRCA)

VISUALIZE

copy number

Copy Number Segment (n=1,111) GDC Hub
More information on the GDC pipeline used to generate this data: https://docs.gdc.cancer.gov/Data/Bioinformatics_Pipelines/CNV_Pipeline/

Masked Copy Number Segment* (n=1,111) GDC Hub
More information on the GDC pipeline used to generate this data: https://docs.gdc.cancer.gov/Data/Bioinformatics_Pipelines/CNV_Pipeline/

copy number (gene-level)

GISTIC - focal score by gene (n=1,104) GDC Hub
The GDC GISTIC copy number dataset is derived from focal copy number estimates. Larger chromosomal-level deletions may not be not captured in this dataset. More information on the GDC pipeline used to generate this data: https://docs.gdc.cancer.gov/Data/Bioinformatics_Pipelines/CNV_Pipeline/

DNA methylation

Illumina Human Methylation 27 (n=342) GDC Hub
More information on the GDC pipeline used to generate this data: https://docs.gdc.cancer.gov/Data/Bioinformatics_Pipelines/Methylation_LO_Pipeline/

Illumina Human Methylation 450 (n=890) GDC Hub
More information on the GDC pipeline used to generate this data: https://docs.gdc.cancer.gov/Data/Bioinformatics_Pipelines/Methylation_LO_Pipeline/

gene expression RNAseq

HTSeq - Counts (n=1,217) GDC Hub
More information on the GDC pipeline used to generate this data: https://docs.gdc.cancer.gov/Data/Bioinformatics_Pipelines/Expression_mRNA_Pipeline/

HTSeq - FPKM (n=1,217) GDC Hub
More information on the GDC pipeline used to generate this data: https://docs.gdc.cancer.gov/Data/Bioinformatics_Pipelines/Expression_mRNA_Pipeline/

HTSeq - FPKM-UQ* (n=1,217) GDC Hub
More information on the GDC pipeline used to generate this data: https://docs.gdc.cancer.gov/Data/Bioinformatics_Pipelines/Expression_mRNA_Pipeline/

基于多组学数据的疾病分类

phenotype

Phenotype (n=1,284) GDC Hub

survival data (n=1,260) GDC Hub

somatic mutation (SNPs and small INDELs)

MuSE Variant Aggregation and Masking (n=983) GDC Hub
More information on the GDC pipeline used to generate this data: https://docs.gdc.cancer.gov/Data/Bioinformatics_Pipelines/DNA_Seq_Variant_Calling_Pipeline/#somatic-variant-calling-workflow

MuTect2 Variant Aggregation and Masking* (n=986) GDC Hub
More information on the GDC pipeline used to generate this data: https://docs.gdc.cancer.gov/Data/Bioinformatics_Pipelines/DNA_Seq_Variant_Calling_Pipeline/#somatic-variant-calling-workflow

SomaticSniper Variant Aggregation and Masking (n=975) GDC Hub
More information on the GDC pipeline used to generate this data: https://docs.gdc.cancer.gov/Data/Bioinformatics_Pipelines/DNA_Seq_Variant_Calling_Pipeline/#somatic-variant-calling-workflow

VarScan2 Variant Aggregation and Masking (n=986) GDC Hub
More information on the GDC pipeline used to generate this data: https://docs.gdc.cancer.gov/Data/Bioinformatics_Pipelines/DNA_Seq_Variant_Calling_Pipeline/#somatic-variant-calling-workflow

stem loop expression

miRNA Expression Quantification (n=1,202) GDC Hub
More information on the GDC pipeline used to generate this data: https://docs.gdc.cancer.gov/Data/Bioinformatics_Pipelines/miRNA_Pipeline/

基于多组学数据的疾病分类

数据类型

(1) 基因表达数据（RNA-seq）

数据矩阵：基因 × 样本（行是基因，列是样本）

常用数据：

- FPKM / TPM（标准化表达量）
- **counts（原始读数，适合差异分析）**
- 用途：基因表达谱可用于区分癌症亚型或正常/肿瘤样本

gene expression RNAseq

HTSeq - Counts (n=1,217) GDC Hub
More information on the GDC pipeline used to generate this data: https://docs.gdc.cancer.gov/Data/Bioinformatics_Pipelines/Expression_mRNA_Pipeline/

HTSeq - FPKM (n=1,217) GDC Hub
More information on the GDC pipeline used to generate this data: https://docs.gdc.cancer.gov/Data/Bioinformatics_Pipelines/Expression_mRNA_Pipeline/

HTSeq - FPKM-UQ* (n=1,217) GDC Hub
More information on the GDC pipeline used to generate this data: https://docs.gdc.cancer.gov/Data/Bioinformatics_Pipelines/Expression_mRNA_Pipeline/

(2) 甲基化数据（DNA Methylation）

数据矩阵：CpG位点 × 样本（行是甲基化探针，列是样本）

常用平台：Illumina 450K/EPIC

用途：甲基化水平可用于表观遗传分类

Probe	TCGA-A1-A0SB-01A	TCGA-A1-A0SD-01A
cg00050873	0.83	0.12
cg00212031	0.45	0.67

数据类型

(3) 拷贝数变异（CNV）

数据矩阵：基因/基因组区域 × 样本（行是基因，列是样本）

常用数据：

GISTIC2 处理后的数据（-2=深度缺失，-1=缺失，0=正常，1=增益，2=扩增）

用途：拷贝数变化可用于识别驱动基因和分子亚型。

Gene_Symbol	TCGA-XX-XXXX	TCGA-YY-YYYY
TP53	-1	0
EGFR	0.58	-0.3

(4) 体细胞突变（SNV/Indel）

数据格式：通常存储为MAF文件（Mutation Annotation Format）

关键信息：

- Hugo_Symbol（基因名）
- Variant_Classification（突变类型，如错义突变、无义突变）

用途：可用于突变特征分析和分类。

Hugo_Symbol	Chromosome	Start_Position	Reference_Allele	Tumor_Seq_Allele	Variant_Classification
TP53	17	7579474	G	A	Missense_Mutation
EGFR	7	55259515	C	T	Nonsense_Mutation

(5) 蛋白质组数据（RPPA）

数据矩阵：蛋白质/磷酸化位点 × 样本（行是蛋白，列是样本）

用途：蛋白活性可用于功能亚型分类。

Sample_ID	TCGA-A1-A0SB-01A	TCGA-A1-A0SD-01A
AKT_pS473	0.85	-0.12
ERK1_pT202	1.34	0.45

基于多组学数据的疾病分类

数据类型

phenotype

Phenotype (n=1,284) GDC Hub

survival data (n=1,260) GDC Hub

(1) 患者基本信息

字段名	说明
`patient_id`	患者唯一ID（如 `TCGA-XX-XXXX`）。
`gender`	性别（`Male` / `Female`）。
`age_at_diagnosis`	诊断年龄（单位：天或年，需注意单位）。
`race`	种族（如 `White`、`Asian`、`Black or African American`）。
`vital_status`	生存状态（`Alive` / `Dead`）。

(2) 肿瘤特征与分期

字段名	说明
`tumor_stage`	肿瘤分期（如 `Stage I`、`Stage IIA`）。
`tumor_grade`	肿瘤分级（如 `G1` - `G4`，分化程度）。
`histological_type`	组织学类型（如 `Infiltrating Ductal Carcinoma`）。
`primary_site`	原发部位（如 `Breast`、`Lung`）。

(3) 治疗信息

字段名	说明
`treatment_type`	治疗类型（如 `Chemotherapy`、`Radiation Therapy`）。
`drug_name`	药物名称（如 `Paclitaxel`）。
`days_to_treatment`	从诊断到治疗的天数（可能为负数，表示术前治疗）。

(4) 生存数据（关键分析字段）

字段名	说明
`days_to_last_followup`	末次随访时间（天）。
`days_to_death`	死亡时间（天，仅当 `vital_status = Dead` 时有效）。
`overall_survival`	总生存期（OS，通常需结合 `vital_status` 计算）。
`progression_free_survival`	无进展生存期（PFS，部分数据集提供）。

基于多组学数据的疾病分类

实验项目流程

数据下载与整合 → 特征选择 → 分类与评估

(1) 癌症 vs 正常样本分类

数据：RNA-seq

步骤：

- 选择差异表达基因（DEG，如 DESeq2）
- 训练随机森林分类器
- 评估AUC-ROC

(2) 癌症分子亚型分类

数据：RNA-seq + 甲基化

步骤：

- 使用 MOFA 降维
- 聚类（如 k-means）
- 用SVM分类新样本

(3) 预后分类（高低风险组）

数据：RNA-seq + CNV + 临床数据

步骤：

- Cox回归筛选特征
- 构建多组学风险评分
- 用XGBoost分类

差异表达分析

年龄预测

NGDC | EWAS Data Hub @EWAS Open Platform | Probes & Genes | Samples | Download | Statistics | Help | EWAS Atlas

It is highly recommended that you download the dataset using a dedicated FTP tool, such as FileZilla Client .
Host address: ftp://download.big.ac.cn/ewas/datahub/download/

Description	Download (.txt & .RData)	File Size
DNA methylation profiles of 31 organism parts	tissue_methylation.zip	7.7 GB
Sample information of DNA methylation profiles of 31 organism parts	sample_tissue_methylation.zip	62.2 KB
DNA methylation profiles of of 25 brain parts	brain_methylation.zip	2.77 GB
Sample information of DNA methylation profiles of of 25 brain parts	sample_brain_methylation.zip	27.2 KB
DNA methylation profiles 25 blood cell types	blood_methylation.zip	4.86 GB
Sample information of DNA methylation profiles 25 blood cell types	sample_blood_methylation.zip	41.8 KB
DNA methylation profiles of male and female in 24 tissues	sex_methylation.zip	4.33 GB
Sample information of DNA methylation profiles of male and female in 24 tissues	sample_sex_methylation.zip	38 KB
DNA methylation changes with age	age_methylation.zip	11.73 GB
Sample information of DNA methylation changes with age	sample_age_methylation.zip	89.3 KB
DNA methylation profiles of 6 ancestry categories	ancestry_category_methylation.zip	1.96 GB
Sample information of DNA methylation profiles of 6 ancestry categories	sample_ancestry_category_methylation.zip	20.9 KB
DNA methylation changes with BMI	bmi_methylation.zip	3.06 GB
Sample information of DNA methylation changes with BMI	sample_bmi_methylation.zip	28.4 KB
DNA methylation profiles of 39 cancers	cancer_methylation.zip	16.07 GB
Sample information of DNA methylation profiles of 39 cancers	sample_cancer_methylation.zip	117.3 KB
DNA methylation profiles of 28 diseases	disease_methylation.zip	20.11 GB
Sample information of DNA methylation profiles of 28 diseases	sample_disease_methylation.zip	154.1 KB

DNA甲基化值（样本ID、探针ID、甲基化值）

样本meta信息（样本ID、年龄、组织等信息）

https://ngdc.cncb.ac.cn/ewas/datahub/download

大作业：基于多组学数据的癌症分类

1、TCGA数据库中的肿瘤数据（可自行选择一种或多种癌症）、DNA甲基化芯片年龄数据

2、转录组、DNA甲基化组、基因组结合临床信息等数据

3、算法选择：传统机器学习算法、深度学习算法等

4、对分类准确度进行评估、对年龄回归要计算MSE等

5、以小组为单位提交一份研究报告（题目、摘要、背景、内容（方法、结论）、总结）

6、5-8人一个小组，在在线文档填写小组成员信息【腾讯文档】生信小组分组及成员

https://docs.qq.com/sheet/DZnRmcUp5c2RjQWt6?tab=BB08J2

生信小组分组及成员
扫一扫二维码打开或分享...